빅데이터 분석 & 자동화 시스템 구축 과정 (1000시간) · 최종 프로젝트 발표

# HOMEPICK

## 공간을 공간답게 — 홈픽

**국토교통부 실거래 빅데이터를 AI가 학습해**
**내 예산과 조건에 맞는 아파트 단지를 찾아 주는 부동산 플랫폼**


팀원

**길길동** (조장) · **박미금** · **김서연** · **홍길동**


2026. 10 | homepick.onrender.com · homepickkr.duckdns.org

**128,941**
건 실거래 학습

**$R^2$ 0.938**
AI 적정가 예측력

**2분 30초**
원클릭 재학습

**2곳**
자동 배포 서버

CONTENTS

# 발표 순서

발표 **길길동**


**01** 프로젝트 개요
팀 소개 · 추진 배경 · 목표
**발표 길길동**

**02** 시스템 설계
아키텍처 · 기술 스택
**발표 길길동 · 홍길동**

**03** 빅데이터 수집 & AI 분석
크롤링 · 전처리 · RandomForest · KMeans
**발표 박미금**

**04** 자동화 & 백엔드
원클릭 재학습 · 회원 인증 · DB/API
**발표 홍길동**

**05** 화면 시연
AI 실거래 단지 추천 · 회원 화면
**발표 김서연**

**06** 배포 · 트러블슈팅 · 성과
CI/CD · 문제 해결 · 향후 계획
**발표 홍길동 · 김서연 · 길길동**

# 팀 소개 및 역할 분담

발표 **길길동**

## 길길동 조장

**조장 · PM · 아키텍처**

- 일정 · 요구사항 관리
- 시스템 아키텍처 설계
- 산출물 문서 총괄
- 최종 통합 · 발표 총괄

## 박미금

**데이터 수집 · AI 모델**

- 공공데이터 API 크롤러 개발
- 전처리 · 이상치 제거 · EDA
- RandomForest 적정가 모델
- KMeans 단지 유형 · 인사이트

## 홍길동

**백엔드 · 자동화 · 배포**

- 회원가입 · 로그인 · BCrypt
- Firebase · 소셜 로그인
- Actions 재학습 자동화
- Render · AWS EC2 CI/CD

## 김서연

**프론트엔드 · UI/UX**

- 화면 설계 · 퍼블리싱
- AI 추천 · 분석 리포트 화면
- Plotly 시각화 · 반응형
- 공통 헤더 · 푸터 · 파비콘

발표 길길동

# 추진 배경 — 왜 '실거래 데이터'인가?

## 01

### 호가 ≠ 실제 거래가

부동산 플랫폼의 매물 가격은 집주인이 부르는 '호가'로, 실제 거래 가격과 차이가 큽니다. 내 예산으로 실제 어떤 단지를 살 수 있었는지 알기 어렵습니다.

## 02

### 흩어진 공공 빅데이터

국토교통부 실거래 데이터는 공개되어 있지만 지역 · 월별 API로 쪼개져 있어 일반 사용자가 모아서 비교 · 분석하기 어렵습니다.

## 03

### '적정 가격' 기준의 부재

같은 지역 · 같은 면적이라도 가격 차이가 큰데, 이 거래가 비싼지 싼지 판단할 객관적인 기준이 없습니다.

**해결 아이디어** 공공 실거래 빅데이터를 자동으로 수집 · 학습해 **AI 적정가** 와 **실제 거래 기록** 으로 단지를 추천하자

발표 **길길동**

# 프로젝트 목표와 핵심 기능

수집 → 분석 → 서비스 → 시각화 → 자동화

### 공공 API 크롤링

수도권 83개 시·군·구
최근 6개월 실거래

### AI 학습

RandomForest 적정가
KMeans 단지 유형

### AI 단지 추천

예산 · 방 수 · 지역
맞춤 순위 + 근거

### 분석 리포트

월별 추이 · 가격 요인
시·군·구 순위 (Plotly)

### 원클릭 재학습

버튼 한 번에 수집→학습
→반영 (약 2분 30초)

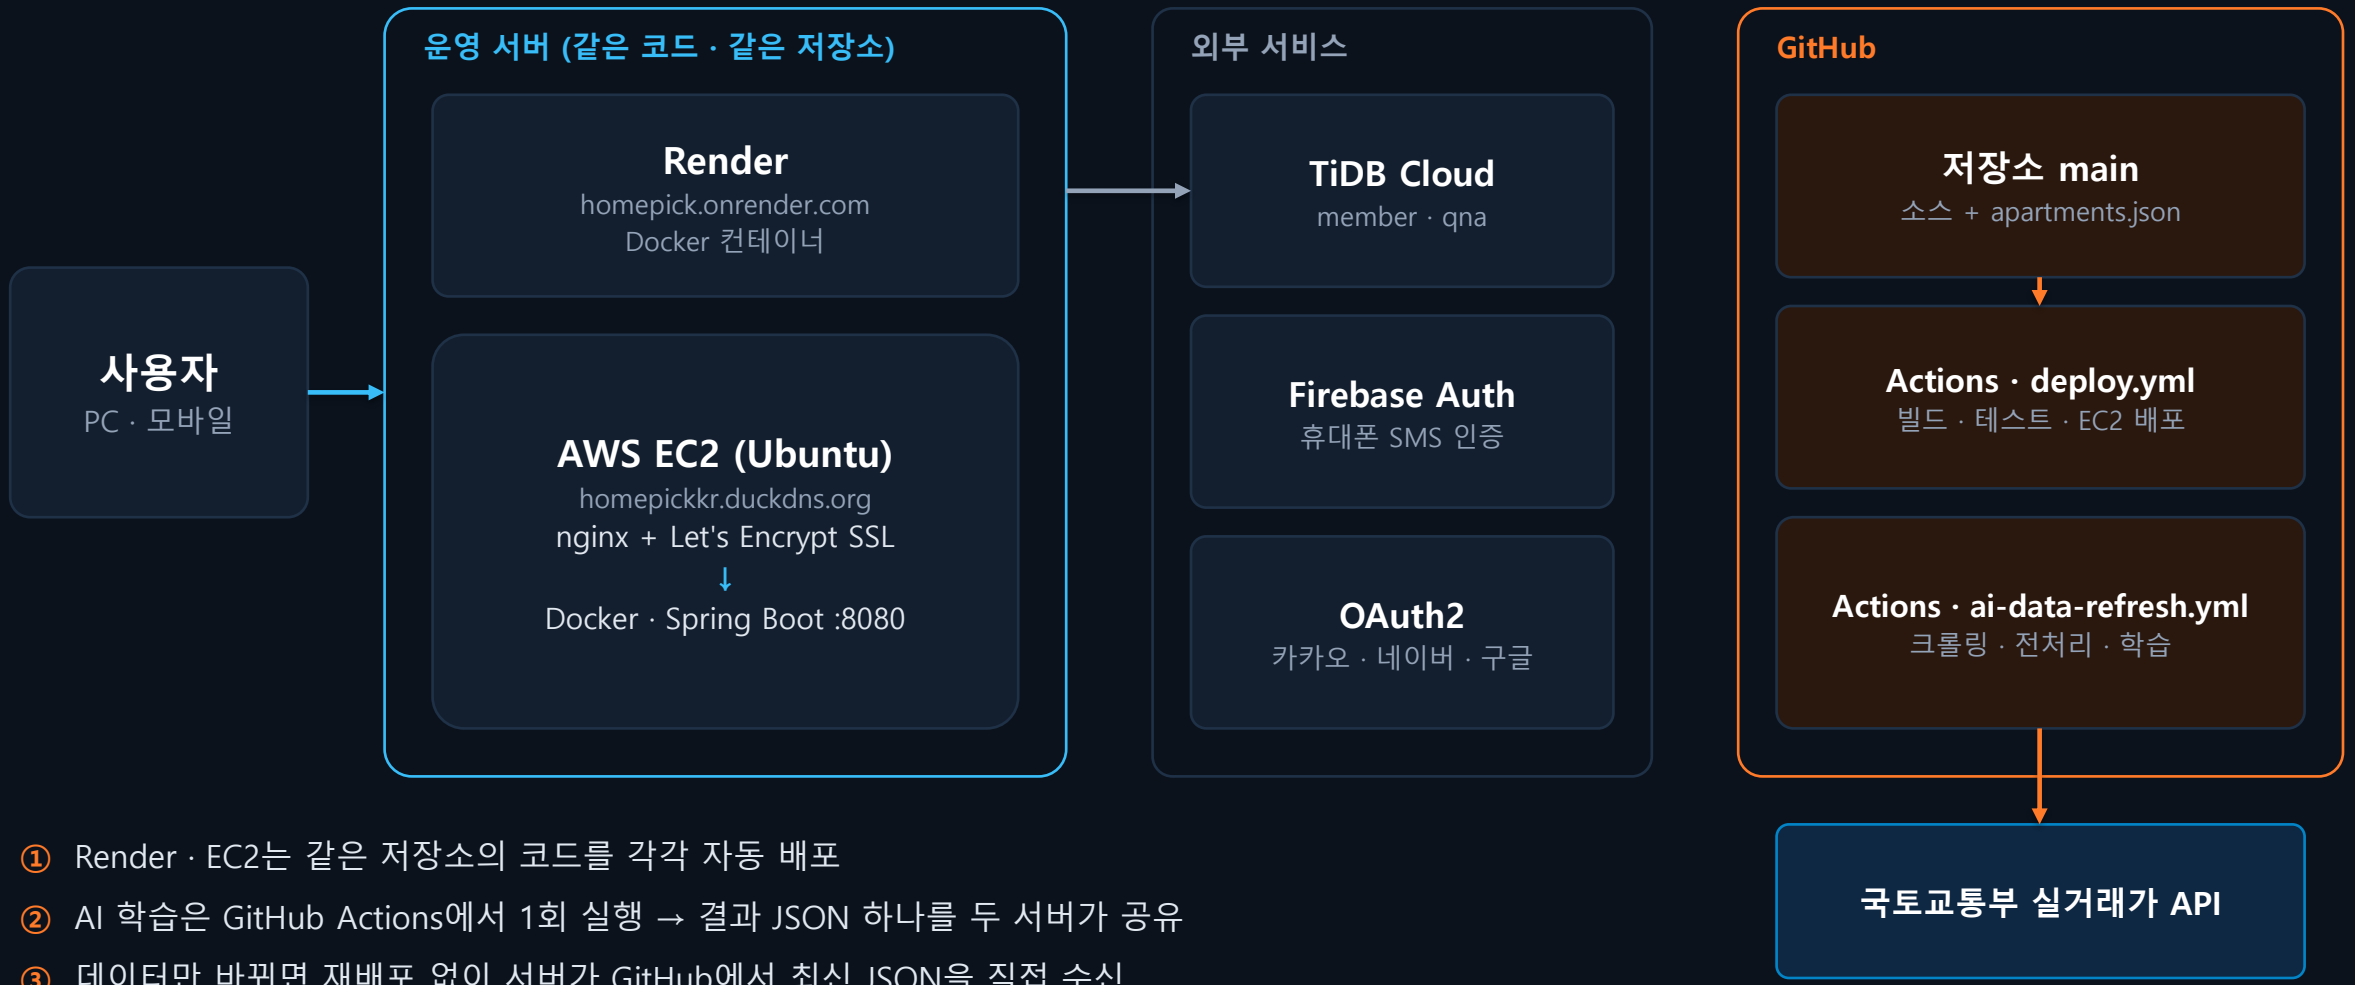
## 함께 구현한 서비스 기능

- 4단계 회원가입 (Firebase 휴대폰 인증)
- 카카오 · 네이버 · 구글 소셜 로그인
- BCrypt 비밀번호 암호화
- Q&A 게시판
- Render · EC2 자동 배포

※ 실거래 데이터는 이미 거래가 끝난 기록이며, 현재 판매 중인 매물과 다를 수 있음을 화면에 명시했습니다.

# 시스템 아키텍처






① Render · EC2는 같은 저장소의 코드를 각각 자동 배포

② AI 학습은 GitHub Actions에서 1회 실행 → 결과 JSON 하나를 두 서버가 공유

③ 데이터만 바뀌면 재배포 없이 서버가 GitHub에서 최신 JSON을 직접 수신

# 기술 스택



## Backend

Java 21 · Spring Boot 4.1
Spring MVC · JdbcTemplate
Spring Security (BCrypt · OAuth2)

## Frontend

Thymeleaf · Bootstrap 5.3
Vanilla JS · Font Awesome
plotly.js 4.1

## Data · AI

Python 3.11 · requests · pandas
scikit-learn (RandomForest · KMeans)
Plotly 7.1 · matplotlib

## Database · 인증

TiDB Cloud (MySQL 호환)
Firebase Phone Auth
Kakao · Naver · Google OAuth2

## 자동화 · CI/CD

GitHub Actions
(빌드 · 테스트 · 배포 · AI 재학습)
Gradle · Docker

## Infra

Render (Docker)
AWS EC2 · nginx · Let's Encrypt
DuckDNS

발표 **박미금**

# 빅데이터 수집 — 공공데이터 API 크롤링

**83** 개 지역
서울 25 · 인천 11 · 경기 47

**6** 개월
2026.04 ~ 2026.09

**498** 회
지역 x 월 API 요청

**128,941** 건
실거래 · 18,129개 단지

## 수집 방식

- 출처: 국토교통부 아파트 매매 실거래가 API (data.go.kr)
- 법정동 코드 5자리 기준, 행정구역 개편(인천 · 화성) 반영
- 8건 동시 병렬 요청 (ThreadPool) + 실패 시 1·2·4초 재시도
- 실패 비율이 높으면 중단하고 원인을 로그 · 화면에 출력

### 병렬 크롤링 성능 개선

개선 전 (순차 요청)

**28분+**

→

개선 후 (8건 병렬)

**27초**

API 응답이 건당 0.7~14.6초로 느렸던 날, 498건을 하나씩 보내면서 재시도 대기까지 쌓인 것이 원인이었습니다.

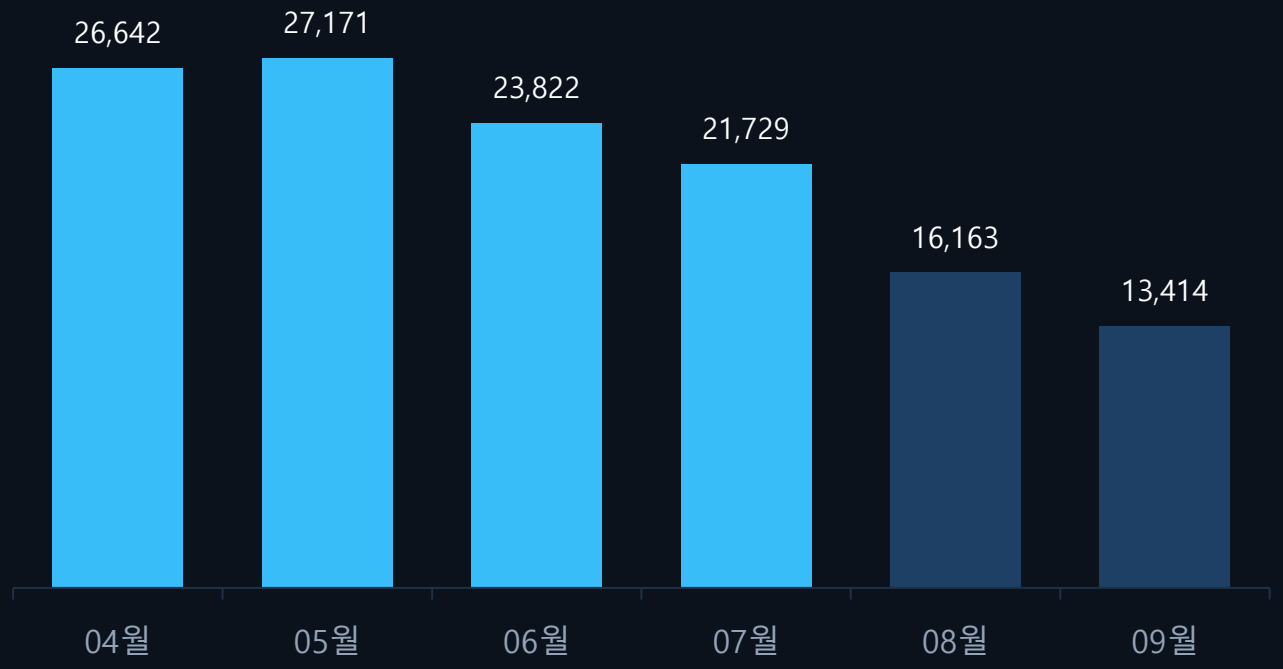
발표 박미금

# 전처리와 탐색적 데이터 분석 (EDA)

## 전처리 단계

1. **정제**
   금액 쉼표 · 공백 제거, 숫자 변환
2. **이상치 제거**
   면적 · 가격 극단값, 해제된 거래 제외
3. **파생 변수**
   평당가, 건물 연식, 계약일
4. **방 수 추정**
   전용면적 40·60·85㎡ 기준 1~4방+

## 수도권 월별 실거래 건수




**인사이트** 중위 거래가 6.3억(5월) → 5.8억(7월)로 하락, 거래가 가장 활발했던 달은 5월(27,171건).
최근 2개월(연한 막대)은 실거래 신고 기한(30일) 때문에 아직 덜 집계된 값입니다.

발표 **박미금**

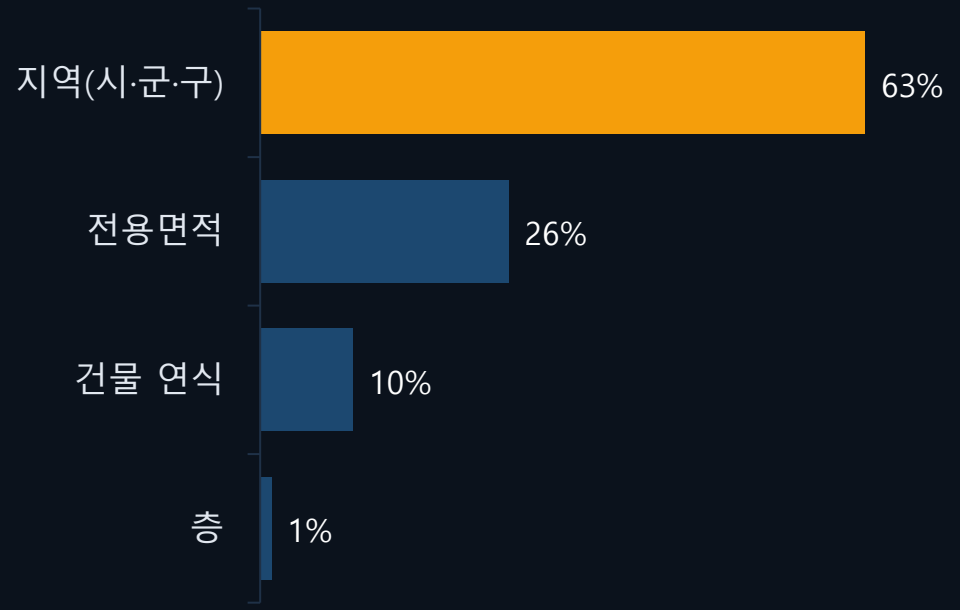
# AI 모델 ① RandomForest — 적정 거래가 예측

| 0.938 | 7,333만원 | 33% |
|---|---|---|
| 결정계수 $R^2$ (예측력) | 평균 절대 오차 (MAE) | 저평가 거래 비율 (적정가보다 5%↓) |

## 모델 구성

- 입력: 전용면적 · 층 · 건물 연식 + 지역(One-Hot)
- RandomForestRegressor (트리 200개, 최소 리프 3)
- 저평가 점수(valueScore) = **AI 적정가 ÷ 실제 거래가**
- 1보다 크면 적정가보다 싸게 거래된 단지

## AI가 본 가격 결정 요인 (Feature Importance)




→ 가격은 **지역(63%)** 과 **전용면적(26%)** 이 대부분 결정하고, 층은 거의 영향이 없었습니다.

발표 박미금

# AI 모델 ② KMeans 단지 유형 & 추천 점수

## KMeans 군집 → 사람이 읽는 단지 유형 이름

| 단지 유형 | 중위 거래가 | 면적 · 연식 | 대표 지역 |
|---|---|---|---|
| 구축·대형·고가 | 35억 | 131㎡ · 24년 | 서울 강남구 |
| 준신축·중형·고가 | 18.2억 | 85㎡ · 11년 | 서울 서초구 |
| 구축·중형·고가 | 15.4억 | 84㎡ · 30년 | 경기 성남시 분당구 |
| 구축·대형·중간가 | 8.3억 | 122㎡ · 23년 | 경기 용인시 수지구 |
| 신축·중소형·중간가 | 5.7억 | 75㎡ · 7년 | 경기 평택시 |

가격 · 면적 · 연식이 비슷한 단지끼리 자동으로 묶고, 군집 중심값으로 '신축 / 구축', '중소형 / 대형', '중간가 / 고가' 이름을 붙였습니다.

## AI 추천 점수 (100점)

**50%** — **조건 근접도**
예산 · 면적에 가까울수록

**35%** — **저평가 점수**
AI 적정가보다 싸게 거래될수록

**15%** — **최근 거래**
최근에 거래된 단지일수록

필터: 희망 지역 → 예산 이하 → 방 수 일치

발표 홍길동

# 원클릭 AI 재학습 자동화 (GitHub Actions)




전체 소요 시간

**약 2분 30초**

Python 서버 없이 GitHub Actions가 크롤링 → 학습 → 결과 커밋까지 전부 자동 실행

## 진행 상태 실시간 표시

- 5초마다 GitHub 실행 단계 조회
- 경과 시간 · 진행 막대 표시
- 단계가 뒤로 가지 않게 보정
- 실패 시 실패 단계와 원인 출력

## 안전 장치

- 로그인 사용자만 실행 (비로그인 401)
- 10분 내 재요청 · 중복 실행 차단
- 크롤링 20분 · 전체 30분 제한
- GitHub 장애 시 내장 JSON 사용

# 회원가입 · 로그인 · 보안

## 4단계 회원가입

| 1. 약관 동의 | 2. 기본 정보 | 3. 휴대폰 인증 | 4. 계정 생성 |
|---|---|---|---|
| 필수 2 · 선택 2<br>전체 동의 연동 | 이름 · 생년월일<br>성별 | Firebase SMS<br>6자리 · 3분 | 아이디 · 비밀번호<br>서버 재검증 |

## 보안 처리

- 비밀번호 **BCrypt 해시** 저장 (평문 저장 없음)
- **Firebase 본인인증 UID** 없이는 가입 불가
- 화면 · 서버 같은 규칙으로 이중 검증 (400 · 409 응답)
- API 키 · DB 비밀번호는 .env · 환경변수 · GitHub Secrets로 분리

## 소셜 로그인 (OAuth2)

**카카오 로그인**

**네이버 로그인**

**구글 로그인**

- 처음 로그인 → 자동 회원가입
- 기존 회원 → 이름 · 이메일 갱신
- Spring Security OAuth2 Client
- nginx 뒤에서도 https 콜백 주소 생성

# 데이터베이스 · API 설계



## TiDB 테이블

| member (회원) | 설명 |
|---|---|
| user_id UK | 로그인 아이디 |
| password_hash | BCrypt 해시 |
| name · birth · gender · phone | 기본 정보 |
| firebase_uid | 휴대폰 본인인증 |
| sns_type · sns_id UK | 소셜 로그인 식별 |

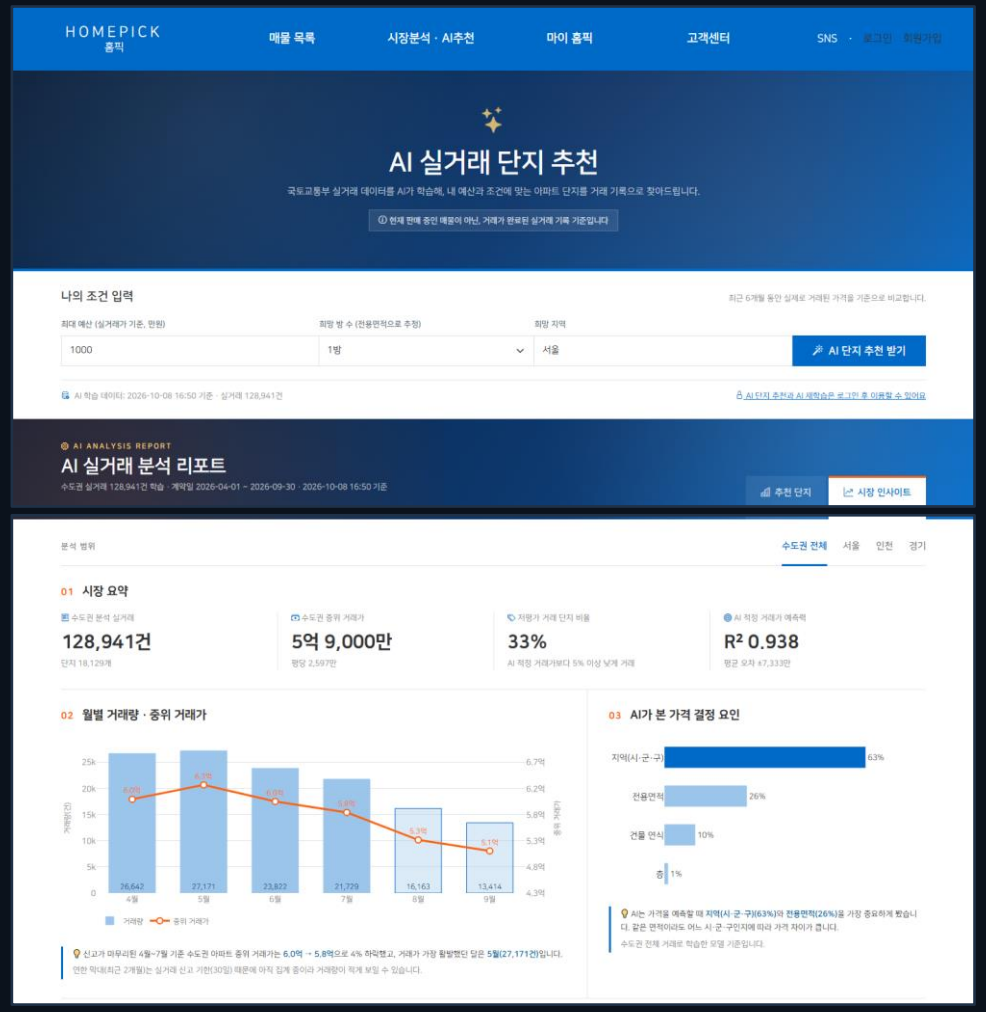
| qna (Q&A) | 설명 |
|---|---|
| title · content · writer | 제목 · 내용 · 작성자 |
| status · created_at | 상태 · 작성일 |

## 주요 API

| Method | URL | 설명 |
|---|---|---|
| POST | /api/members/register | 회원가입 (JSON) |
| POST | /member/login | 아이디 로그인 |
| GET | /oauth2/authorization/{sns} | 소셜 로그인 |
| GET | /api/ai-data/apartments | AI 학습 데이터 (gzip) |
| GET | /api/ai-data/status | 재학습 진행 상태 |
| POST | /api/ai-data/refresh | AI 재학습 (로그인) |
| GET | /qna | Q&A 목록 |
| GET | /healthz | 헬스 체크 |

# AI 실거래 단지 추천 화면

발표 김서연




① **실거래 기준 안내**

'판매 중인 매물이 아닌 거래 완료 기록' 명시

② **조건 입력 바**

예산 · 방 수 · 지역 → AI 단지 추천 받기

③ **재학습 버튼 · 진행 표시**

로그인 사용자 전용, 단계 · 경과 시간

④ **AI 실거래 분석 리포트**

추천 단지 / 시장 인사이트 탭

⑤ **시장 인사이트**

수도권 · 서울 · 인천 · 경기 범위 탭, 시장 요약 지표

⑥ **Plotly 그래프**

Python에서 만든 그래프를 plotly.js로 표시

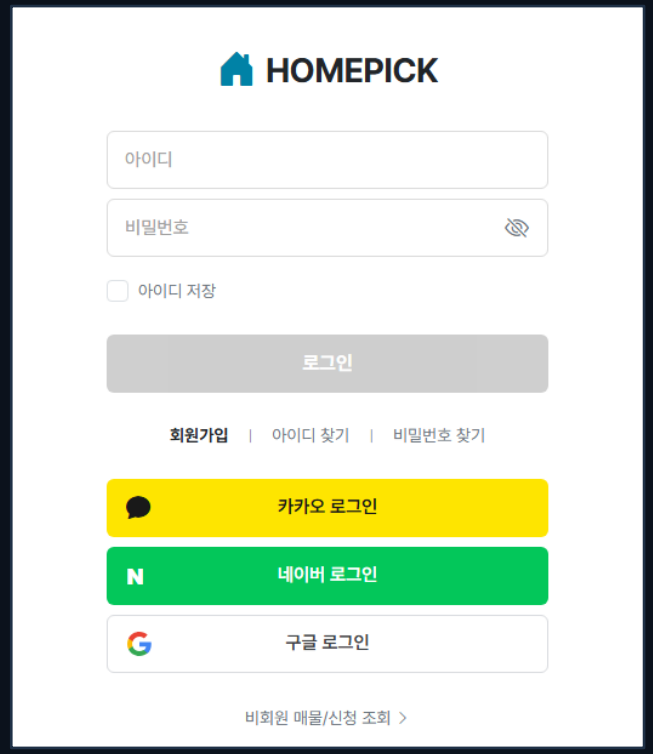
# 회원가입 · 로그인 · Q&A 화면

발표 김서연




## 회원가입 (1단계 약관)

전체 동의 ↔ 개별 4개 연동




## 로그인

아이디 로그인 + 소셜 로그인 3종

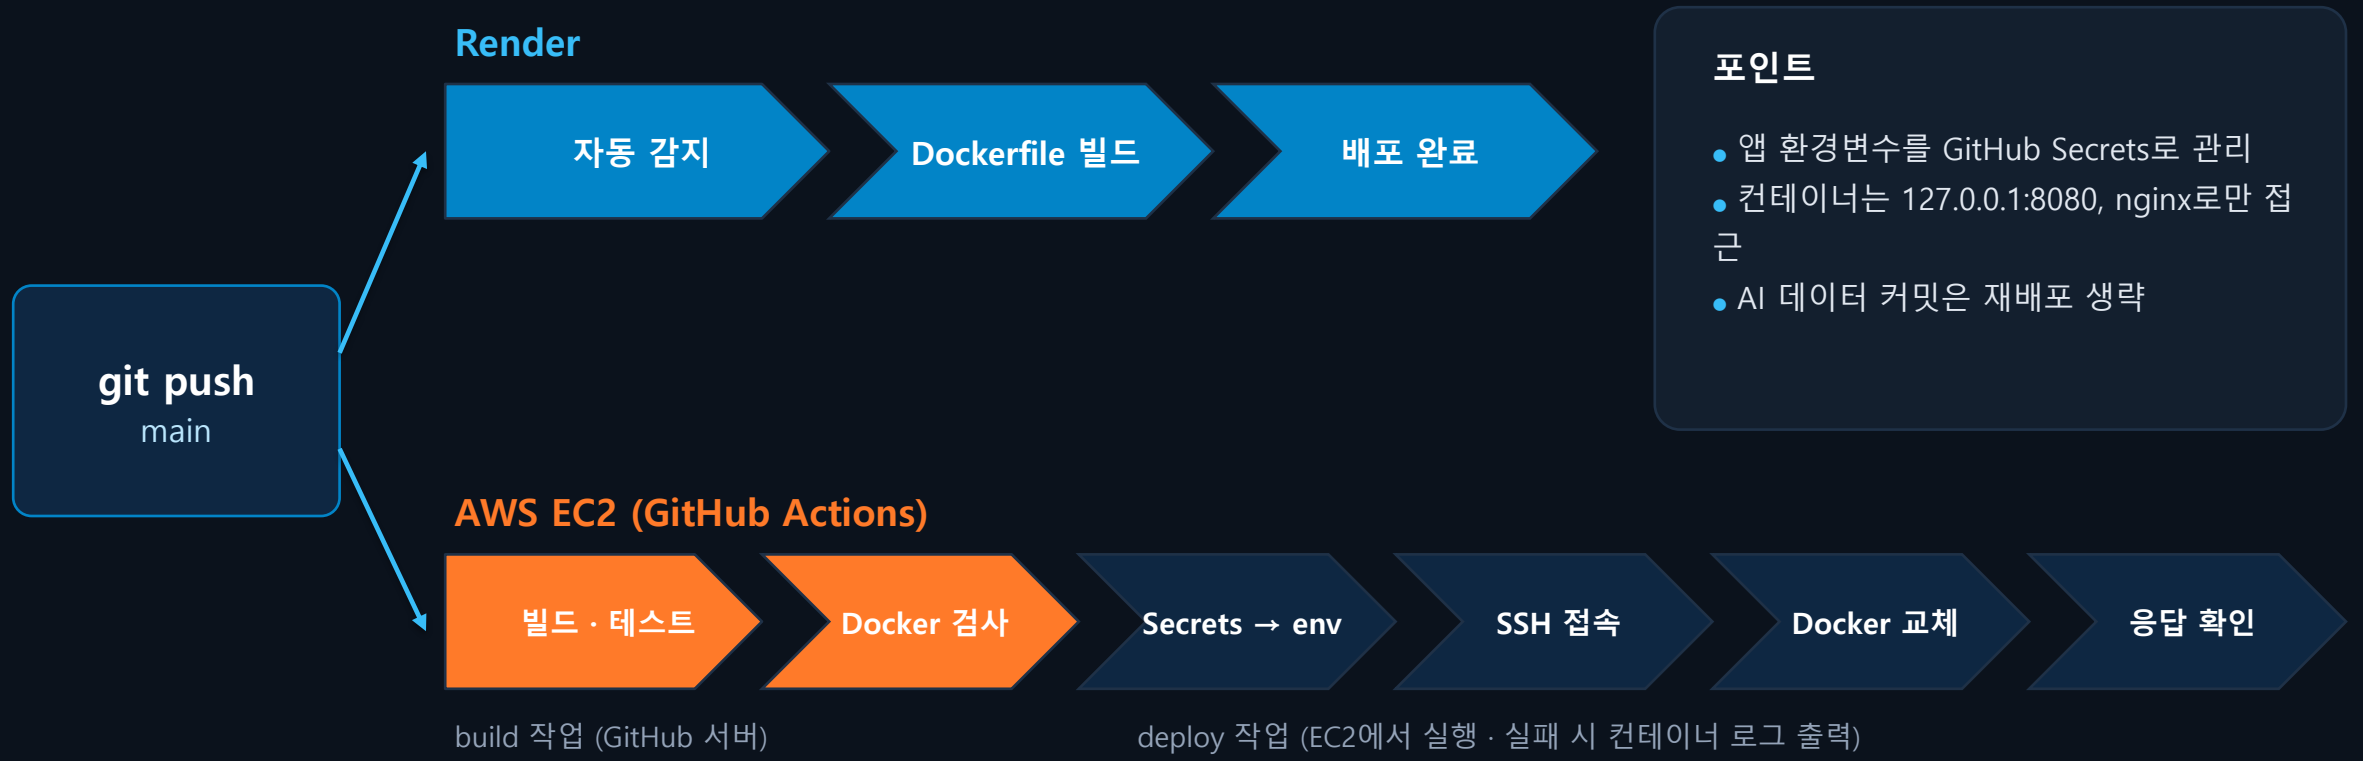



## Q&A 게시판

TiDB qna 테이블 목록

발표 **홍길동**

# CI/CD 배포 자동화




**포인트**

- 앱 환경변수를 GitHub Secrets로 관리
- 컨테이너는 127.0.0.1:8080, nginx로만 접근
- AI 데이터 커밋은 재배포 생략

**결과** **코드를 main에 올리기만 하면 테스트를 통과한 버전이 Render와 EC2 두 곳에 자동 배포됩니다.**

발표 **김서연**

# 트러블슈팅 — 문제를 이렇게 해결했습니다

| 문제 | 원인 | 해결 | 결과 |
|---|---|---|---|
| **AI 재학습 중 크롤링이 27분 넘게 끝나지 않음** | API 응답 지연(건당 최대 14.6초) + 498건 순차 요청 | 8건 병렬 요청, 재시도 대기 단축, 단계별 시간 제한 | 크롤링 27초 · 전체 2분 30초 |
| **진행 표시가 '전처리 → 크롤링'으로 되돌아감** | GitHub 단계 정보가 순간적으로 어긋나게 조회됨 | 가장 많이 진행된 단계를 기억해 뒤로 가지 않게 보정 | 단계 순서 항상 일치 |
| **GitHub Actions 빌드(테스트) 실패** | CI 환경에 소셜 로그인 client-id가 없어 앱 시작 실패 | 테스트에서만 더미 client-id 지정 (운영 설정 유지) | CI 빌드 · 테스트 통과 |
| **EC2 자동 배포가 SSH 연결에서 실패** | 인스턴스 재시작으로 퍼블릭 IP 변경, Secret에는 예전 IP | EC2_HOST를 도메인으로 변경, IP 등록 시 경고 출력 | IP가 바뀌어도 배포 유지 |
| **'매물 추천'이 현재 매물로 오해될 수 있음** | 데이터는 거래가 끝난 실거래 기록 | 페이지 · 문구를 '실거래 단지 추천'으로 전면 수정 | 데이터 의미를 정확히 전달 |

**→ 모든 문제와 해결 과정은 저장소 docs/ 폴더에 문서로 기록해 팀 전체가 공유했습니다.**

발표 **길길동**

# 프로젝트 성과와 향후 계획

## 성과

**12.9 만 건**
수도권 실거래 학습

**0.938 $R^2$**
AI 적정가 예측력

**98 % 단축**
크롤링 시간 (28분+ → 27초)

**2 곳**
자동 배포 (Render · EC2)

**수집 → 분석 → 서비스 → 시각화 → 자동화를**
**하나의 파이프라인으로 연결해 실제 운영 중**

## 향후 계획

- 전월세 실거래 · 전국 단위로 데이터 확장
- 시계열 예측 모델로 향후 가격 추이 예측
- XGBoost 등 모델 비교로 예측 정확도 개선
- 스케줄러로 매일 자동 재학습
- 지도 기반 단지 조회 · 관심 단지 알림
- Q&A 글쓰기 · 마이페이지 등 미구현 메뉴 완성

# 감사합니다

## Q & A

HOMEPICK — 빅데이터 분석 & 자동화 시스템 구축 과정 최종 프로젝트

**길길동** (조장) · **박미금** · **김서연** · **홍길동**

**https://homepick.onrender.com** · **https://homepickkr.duckdns.org**

**github.com/fsclass-n/homepick_lo**